



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
ΤΜΗΜΑ ΨΗΦΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ
ΜΑΘΗΜΑ: Ανάκτηση Πληροφοριών
ΕΞΑΜΗΝΟ: 8^ο

ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025-26

ΔΙΔΑΣΚΩΝ: Χρήστος Δουλκερίδης (cdoulik@unipi.gr)

Θέμα εργασίας:

Αναζήτηση κοντινότερων γειτόνων σε υψηλής διάστασης διανυσματικά δεδομένα με χρήση αντεστραμμένου ευρετηρίου

Πρόβλημα: Δίνεται μεγάλο σύνολο διανυσματικών δεδομένων S που περιέχει n -διάστατα διανύσματα και ζητείται η υλοποίηση αλγόριθμου που δοθέντος ενός διανύσματος-ερώτησης q , υπολογίζει τα k κοντινότερα διανύσματα βάσει ευκλείδειας απόστασης $d(q, s_i)$ όπου $s_i \in S$, δηλαδή επιστρέφει το υποσύνολο διανυσμάτων R :

$$R = \{s_i \in S: d(q, s_i) \leq d(q, s_j) \text{ για κάθε } s_j \in R \text{ και } s_j \in S - R\}, |R|=k$$

Στόχος της εργασίας είναι η υλοποίηση **δύο αλγορίθμων** που επιλύουν το πρόβλημα, ενός ακριβούς και ενός προσεγγιστικού. Ο **ακριβής αλγόριθμος** επιστρέφει το σύνολο των διανυσμάτων που αποτελούν λύση του προβλήματος. Συνήθως όμως είναι εμπεριέχει υψηλό κόστος επεξεργασίας και είναι σχετικά αργός. Ο **προσεγγιστικός αλγόριθμος** αποσκοπεί να υπολογίσει μια λύση που να είναι πολύ κοντά στην ακριβή λύση, αλλά με πολύ μικρότερο κόστος επεξεργασίας.

Για την υλοποίηση των αλγορίθμων θα χρησιμοποιηθεί μια προσέγγιση που στηρίζεται στη χρήση αντεστραμμένων ευρετηρίων (inverted indexes). Συγκεκριμένα, η προσέγγιση που θα ακολουθηθεί θα έχει τα εξής χαρακτηριστικά:

- Θα ομαδοποιεί τα διανύσματα σε P ομάδες με βάση την μεταξύ τους απόσταση, με σκοπό να εντοπίζει τα ζητούμενα k κοντινότερα διανύσματα εξετάζοντας λίγες ομάδες μόνο. Η ομαδοποίηση γίνεται σε φάση προεπεξεργασίας και μπορεί να χρησιμοποιηθεί ένας αλγόριθμος συσταδοποίησης, όπως ο k -means.
- Η κάθε ομάδα μπορεί να αντιπροσωπεύεται από ένα διάνυσμα που συνήθως είναι το κεντροειδές διάνυσμα (εκείνο που προκύπτει από το μέσο όρο όλων των διανυσμάτων της ομάδας).
- Εντός της κάθε ομάδας, τα διανύσματα οργανώνονται σε μια δομή αντεστραμμένου ευρετηρίου. Η διάταξη των διανυσμάτων στη λίστα καταχώρισης μπορεί να επιλεγεί ώστε να είναι επωφελής για τον αλγόριθμο επεξεργασίας.
- Ο προσεγγιστικός αλγόριθμος μπορεί να εξετάζει τις M ($M < P$) πιο υποσχόμενες ομάδες όπου με μεγαλύτερη πιθανότητα θα περιέχονται κοντινότεροι γείτονες του q . Το M μπορεί να είναι παράμετρος εισόδου. Όμως, θα ήταν πιο ενδιαφέρον αν μπορεί να υπολογίζεται αυτόματα κατά την εκτέλεση του αλγορίθμου.

- Επίσης ο προσεγγιστικός αλγόριθμος θα μπορούσε να μην εξετάζει όλα τα διανύσματα εντός μιας ομάδας, εάν μπορεί κάπως να διαπιστωθεί ότι τα εναπομείναντα διανύσματα δεν αποτελούν μέρος του αποτελέσματος αναζήτησης.
- Ιδιαίτερη αξία στον προσεγγιστικό αλγόριθμο θα είχε η ανάπτυξη ενός μηχανισμού τερματισμού, που θα διέκοπτε τη λειτουργία του αλγορίθμου όταν είχε μια εκτίμηση ότι περαιτέρω αναζήτηση δε θα συνεισφέρει πολύ ή καθόλου στο τελικό αποτέλεσμα.

Σημαντικό κομμάτι της εργασίας είναι η πειραματική αξιολόγηση των αλγορίθμων. Για το σκοπό αυτό, θα πρέπει να χρησιμοποιηθούν κατάλληλες μετρικές, όπως: χρόνος εκτέλεσης, αριθμός αποστάσεων που υπολογίστηκαν, αλλά και η ανάκληση (recall) του προσεγγιστικού αλγορίθμου. Συνιστάται η χρήση της μετρικής QPS (queries per second) αντί του χρόνου, δηλαδή του αριθμού των ερωτημάτων που εκτελούνται στη μονάδα του χρόνου.

Η αξιολόγηση της εργασίας λαμβάνει υπόψη τον κώδικα που θα αναπτυχθεί (ορθότητα, δυσκολία υλοποίησης), την πρωτοτυπία σε επίπεδο προσέγγισης, την πειραματική αξιολόγηση και την ποιότητα της τεχνικής αναφοράς.

ΣΥΝΟΛΑ ΔΕΔΟΜΕΝΩΝ

Για την εκπόνηση της εργασίας, θα χρησιμοποιηθεί σε πρώτη φάση το σύνολο δεδομένων **SIFT** από τον σύνδεσμο: <ftp://ftp.irisa.fr/local/texmex/corpus/sift.tar.gz> που περιέχει διανυσματικά δεδομένα και διανύσματα-ερωτήματα. Κατά τη διάρκεια του εξαμήνου ενδέχεται να ανακοινωθεί και άλλο σύνολο δεδομένων προς χρήση.

ΓΕΝΙΚΕΣ ΠΛΗΡΟΦΟΡΙΕΣ

- Η εργασία θα εκπονηθεί **ατομικά**.
- Η γλώσσα προγραμματισμού μπορεί να είναι μια εκ των: Java, C/C++, Python.
- Εάν η υλοποίηση περιέχει κομμάτια κώδικα από άλλες πηγές (π.χ. βιβλία, Διαδίκτυο, βιβλιοθήκες που έχουν αναπτύξει άλλοι, άλλες εργασίες, κτλ), πρέπει **απαραίτητα** να αναφέρετε την πηγή προέλευσης. Εργασίες που θα εντοπιστούν να περιέχουν αντιγραφή κώδικα από οπουδήποτε χωρίς αναφορά θα μηδενιστούν.
- ΠΑΡΑΔΟΣΗ: **Στην ημερομηνία εξέτασης του μαθήματος, αποκλειστικά μέσω του «Αρίσταρχου».**

ΠΑΡΑΔΟΤΕΑ

Με την ολοκλήρωση της εργασίας, θα πρέπει να παραδώσετε σε **1 συμπιεσμένο αρχείο** με μορφή **zip** τα ακόλουθα περιεχόμενα:

- Τον κώδικα που αναπτύξατε (πηγαίο και σε εκτελέσιμη μορφή)
- Μια λεπτομερή αναφορά σε μορφή **pdf** που περιγράφει αναλυτικά το τι ακριβώς έχετε υλοποιήσει με παραπομπές για αλγορίθμους και τεχνικές που υιοθετήσατε
 - Θα περιέχεται επεξήγηση του αλγορίθμου με παράδειγμα και εικόνα
 - Θα διεξαχθεί πειραματική αξιολόγηση και τα αποτελέσματα θα εμφανίζονται σε διαγράμματα όπου θα μεταβάλλεται κάποια παράμετρος που ενδιαφέρει, όπως το πλήθος των διανυσμάτων **|S|**, η τιμή του **k**, οι ομάδες **M** που εξετάζονται, κ.ο.κ.

Ονομασία αρχείου: **ΑρΜητρώου_Επώνυμο-Όνομα.zip** (π.χ. **19123_Doulkeridis-Christos.zip**).